

## 1. Συλλογή Εγγράφων

### Πηγή Δεδομένων

Για την κατασκευή του συστήματος θα χρησιμοποιήσουμε μια έτοιμη συλλογή ειδησεογραφικών άρθρων του CNN. Η συλλογή αυτή περιλαμβάνει περίπου 38.000 άρθρα από τα έτη 2011 έως 2022 και είναι διαθέσιμη στο Kaggle:

<https://www.kaggle.com/datasets/hadasu92/cnn-articles-after-basic-cleaning/data>

Το σύστημα που αναπτύσσουμε είναι μια μηχανή αναζήτησης, που θα δέχεται ερωτήματα από τον χρήστη και θα του επιστρέφει σχετικά άρθρα από αυτή τη συλλογή.

### Πεδία Εγγράφων

Κάθε άρθρο στη βάση μας περιέχει τις παρακάτω πληροφορίες:

- **Headline (Τίτλος):** Ο τίτλος του άρθρου
- **Description (Περίληψη):** Μια σύντομη περιγραφή του περιεχομένου
- **Full Text (Κείμενο):** Το πλήρες άρθρο
- **Author (Συγγραφέας):** Το όνομα του συντάκτη
- **Publication Date (Ημερομηνία Δημοσίευσης):** Πότε δημοσιεύθηκε το άρθρο
- **Category (Κατηγορία):** Το θεματικό πεδίο του άρθρου (π.χ. Πολιτική, Οικονομία κ.ά.)
- **URL:** Ο σύνδεσμος για να ανοίξει κανείς το άρθρο στο διαδίκτυο

## 2. Σχεδιασμός Συστήματος

### 2.1 Εισαγωγή

Η μηχανή αναζήτησης που θα φτιάξουμε θα επιτρέπει στον χρήστη να:

1. Ψάχνει άρθρα με λέξεις-κλειδιά σε όλο το περιεχόμενο
2. Αναζητά άρθρα με βάση συγκεκριμένα πεδία, όπως τον τίτλο ή τον συγγραφέα
3. Κάνει πιο ακριβή αναζήτηση χρησιμοποιώντας φράσεις (π.χ. "κλιματική αλλαγή")
4. Βλέπει το ιστορικό των προηγούμενων αναζητήσεών του και να τις επαναφέρει εύκολα

### 2.2 Ανάλυση Κειμένου και Ευρετηρίαση

Κάθε άρθρο θα εισαχθεί ως ξεχωριστό έγγραφο στο ευρετήριο της Lucene. Το ευρετήριο αυτό είναι το βασικό εργαλείο που μας επιτρέπει να κάνουμε γρήγορη και αποτελεσματική αναζήτηση στα κείμενα.

### 2.3 Αναζήτηση

Τύποι Αναζήτησης:

1. **Keyword search:** Γενική αναζήτηση λέξεων-κλειδιών σε όλα τα πεδία κειμένου

2. **Field search:** Αναζήτηση μόνο σε συγκεκριμένα πεδία (π.χ. author:"Smith")

**Ιστορικό Αναζητήσεων:**

- Το σύστημα θα κρατά τις 20 πιο πρόσφατες αναζητήσεις του χρήστη
- Ο χρήστης θα μπορεί να δει και να ξαναχρησιμοποιήσει τις προηγούμενες αναζητήσεις
- Το ιστορικό θα εμφανίζεται στην οθόνη, ώστε να είναι πάντα προσβάσιμο

**2.4 Παρουσίαση Αποτελεσμάτων**

**Διάταξη Αποτελεσμάτων:**

- Προεπιλεγμένη ταξινόμηση με βάση τη σχετικότητα των αποτελεσμάτων (βάσει του Lucene score)
- Εναλλακτικά, ο χρήστης μπορεί να ταξινομήσει τα άρθρα χρονολογικά

**Εμφάνιση Αποτελεσμάτων:**

- Τα αποτελέσματα θα εμφανίζονται σελίδα-σελίδα, 10 άρθρα τη φορά
- Υπάρχουν κουμπιά για πλοήγηση στα επόμενα ή προηγούμενα αποτελέσματα (Next/Previous)
- Οι λέξεις-κλειδιά θα τονίζονται μέσα στα αποτελέσματα
- Κάθε άρθρο θα εμφανίζει μια σύντομη προεπισκόπηση για να καταλαβαίνει ο χρήστης γρήγορα αν τον ενδιαφέρει
- Θα υπάρχει η δυνατότητα τα αποτελέσματα να εμφανίζονται αλφαβητικά με βάση τον τίτλο τους.

**Διεπαφή Χρήστη:**

- Στο κέντρο της σελίδας θα εμφανίζονται τα αποτελέσματα της αναζήτησης
- Στα αριστερά θα υπάρχει μπάρα με το ιστορικό των αναζητήσεων
- Θα υπάρχουν επίσης επιλογές για ταξινόμηση και φιλτράρισμα των αποτελεσμάτων