




# Ανάκτηση Πληροφορίας

Μηχανή Αναζήτησης  
Ειδησεογραφικών Άρθρων


ΑΜΑΛΙΑ-ΓΕΩΡΓΙΑ ΜΟΥΣΕΛΙΜΗ 5074  
ΣΑΚΕΛΛΑΡΙΟΥ ΙΩΑΝΝΑ 5125

## Εισαγωγή

Το σύστημα είναι μια μηχανή αναζήτησης σε μια συλλογή με ειδησεογραφικά άρθρα. Η αναζήτηση μπορεί να γίνει με τους εξής τρόπους:


- αναζήτηση με λέξεις κλειδιά
- αναζήτηση πεδίου (Author, Headline, Category, Section, Description, Second Headline, Article text, Date published)
- διανυσματική αναζήτηση

Ο χρήστης πληκτρολογεί το ερώτημα του στην γραμμή αναζήτησης της μηχανής και έπειτα μέσω των επιλογών που του παρέχονται ("Search by Keyword", "Search by field", "Search by Vector"), μπορεί να επιλέξει τον τρόπο αναζήτησης που επιθυμεί.




The image shows a search interface titled "Article Search". It features a search input field with the placeholder text "Search...". Below the input field, there are three radio buttons for selecting the search method: "Search By Keyword" (which is selected), "Search By Field:", and "Search By Vector". The "Search By Field:" option has a dropdown menu currently showing "headline".

Κάτω από τις επιλογές αναζήτησης υπάρχουν επιλογές για την σειρά με την οποία θα εμφανίζονται τα αποτελέσματα της αναζήτησης. Επίσης, υπάρχει και το κουμπί για την δημιουργία ευρετηρίου, το οποίο θα χρησιμοποιηθεί μόνο μια φορά από τον χρήστη. Τέλος, υπάρχουν τα κουμπιά "Search" και "Clear", με τα οποία ο χρήστης θα εκτελεί την αναζήτηση και θα κάνει εκκαθάριση αντίστοιχα.




The image shows a row of four buttons: "Relevance" with a dropdown arrow, "Create Index" with a download icon, "Search" with a magnifying glass icon, and "Clear" with an eraser icon.

Τα αποτελέσματα εμφανίζονται στο κέντρο της οθόνης και υπάρχουν και βελάκια για να περιηγηθείς στην επόμενη και προηγούμενη καρτέλα αντίστοιχα.



The image shows a search results interface titled "Results:". It features a large empty rectangular box for displaying the search results. At the bottom of the interface, there are two buttons: "Previous" with a left arrow and "Next" with a right arrow.

Στο κάτω μέρος της οθόνης υπάρχει το ιστορικό αναζήτησης του χρήστη που θα εμφανίζει τις 20 τελευταίες αναζητήσεις μαζί με τα 5 πρώτα άρθρα για κάθε μία από αυτές.



## Επεξήγηση Κώδικα

Αρχικά υλοποιήσαμε την κλάση *'CsvLoader'* που είναι υπεύθυνη για την φόρτωση των δεδομένων από το αρχείο csv και τη μετατροπή τους σε δομή δεδομένων (λίστα από πίνακες συμβολοσειρών) ώστε να μπορεί να γίνει η επεξεργασία τους κατά το indexing.

Η κλάση *'Indexer'* είναι υπεύθυνη για την δημιουργία του ευρετηρίου. Η μέθοδος *'createIndex'* ξεκινά με τη φόρτωση των άρθρων από αρχείο CSV, χρησιμοποιώντας την κλάση *CsvLoader*. Κάθε γραμμή του αρχείου αντιστοιχεί σε ένα άρθρο και αποθηκεύεται ως πίνακας *String[]*. Για κάθε άρθρο, δημιουργείται ένα *Document* το οποίο περιλαμβάνει όλα τα βασικά πεδία του άρθρου: *headline*, *author*, *category*, *section*, *description*, *article\_text*, *url*, *date\_published*. Επίσης, στην *Indexer* δημιουργείται για κάθε άρθρο μια διανυσματική αναπαράσταση (*embedding*). Το *embedding* αυτό προκύπτει από το συνδυασμό του τίτλου, του συγγραφέα, της περιγραφής και του πλήρους κειμένου του άρθρου και της επικεφαλίδας. Το διανυσματικό πεδίο αποθηκεύεται στο *Document* μέσω του *KnnVectorField*, το οποίο επιτρέπει μελλοντική αναζήτηση βασισμένη στην ομοιότητα διανυσμάτων.

Για την υλοποίηση της διανυσματικής αναζήτησης δημιουργήσαμε και την κλάση *'EmbeddingHelper'*. Η κλάση αυτή αποτελεί μία στατική βοηθητική μονάδα υπεύθυνη για τη μετατροπή φυσικού κειμένου σε διανυσματική αναπαράσταση (*embedding*), χρησιμοποιώντας το προεπιλεγμένο μοντέλο της HuggingFace μέσω της βιβλιοθήκης DJL. Το *embedding* χρησιμοποιείται για την υποστήριξη διανυσματικής αναζήτησης με KNN (K-nearest neighbors) στο Lucene. Η φόρτωση του μοντέλου γίνεται μία φορά κατά την εκκίνηση, εξασφαλίζοντας αποδοτικότητα κατά την επαναλαμβανόμενη χρήση του *embedText()*.

Η κλάση *'Searcher'* είναι υπεύθυνη για την εκτέλεση αναζητήσεων στο ευρετήριο που δημιουργείται με το Lucene. Υποστηρίζει τρεις βασικούς τύπους αναζήτησης:

**1. Αναζήτηση με λέξεις-κλειδιά (Keyword Search):**

Επιτρέπει την αναζήτηση μιας λέξης ή φράσης σε πολλαπλά πεδία του άρθρου, όπως τίτλος, συγγραφέας, περιγραφή κ.ά. Η αναζήτηση βασίζεται σε συντακτική αντιστοίχιση, δηλαδή αναζητά ακριβείς όρους.

**2. Αναζήτηση σε συγκεκριμένο πεδίο (Field Search):**

Επιτρέπει στο χρήστη να περιορίσει την αναζήτηση σε ένα συγκεκριμένο πεδίο (π.χ. μόνο στον τίτλο ή μόνο στο συγγραφέα), ώστε να επιτευχθεί πιο στοχευμένη ανάκτηση αποτελεσμάτων.

**3. Διανυσματική αναζήτηση (Vector Search):**

Χρησιμοποιεί μοντέλο από τη βιβλιοθήκη DJL για να μετατρέψει το ερώτημα του χρήστη σε διάνυσμα εννοιών. Έπειτα, μέσω του μηχανισμού KnnVectorQuery, βρίσκει άρθρα που είναι σημασιολογικά σχετικά, ακόμη κι αν δεν περιέχουν τις ίδιες λέξεις.

Η κλάση φορτώνει το ευρετήριο κάθε φορά που γίνεται αναζήτηση και επιστρέφει τα αντίστοιχα έγγραφα. Η μέθοδος της διανυσματικής αναζήτησης συνδέεται άμεσα με την 'EmbeddingHelper' η οποία δημιουργεί το διάνυσμα του ερωτήματος.

Η κλάση 'HistoryManager' είναι υπεύθυνη για τη διαχείριση του ιστορικού αναζητήσεων του χρήστη. Καταγράφει μέχρι και τις 20 πιο πρόσφατες αναζητήσεις, μαζί με τα πρώτα 5 αποτελέσματα κάθε αναζήτησης (συνήθως τίτλοι άρθρων). Επιπλέον, αποθηκεύει τον τύπο της αναζήτησης (keyword, field ή διανυσματική), προσφέροντας έτσι ένα πλήρες ιστορικό της αναζήτησης που πραγματοποιήθηκε.

Η κλάση 'AppGUI' αποτελεί το γραφικό περιβάλλον χρήστη (GUI) της εφαρμογής αναζήτησης, υλοποιημένο με τη βιβλιοθήκη JavaFX. Σκοπός της είναι να παρέχει στον χρήστη ένα φιλικό και λειτουργικό περιβάλλον για να εκτελεί αναζητήσεις σε ειδησεογραφικά άρθρα.

## **Βασικές λειτουργίες:**

- **Αναζήτηση άρθρων** με τρεις τρόπους:
  - Με βάση λέξεις-κλειδιά (σε όλα τα πεδία).
  - Με βάση συγκεκριμένο πεδίο (π.χ. τίτλος, συγγραφέας).
  - Με διανυσματική αναζήτηση (vector search).
- **Ταξινόμηση** αποτελεσμάτων ανά:
  - Σχετικότητα,
  - Αλφαβητικά (τίτλος),
  - Ημερομηνία δημοσίευσης.

- **Επισήμανση (highlighting)** των λέξεων-κλειδιών στα αποτελέσματα, με έντονη γραφή.
- **Εμφάνιση σελιδοποιημένων αποτελεσμάτων** (10 ανά σελίδα) με κουμπιά για περιήγηση σε επόμενη ή προηγούμενη σελίδα.
- **Διατήρηση ιστορικού** των τελευταίων 20 αναζητήσεων, μαζί με τους τίτλους των 5 πρώτων αποτελεσμάτων κάθε φορά.