




Ανάκτηση Πληροφορίας

Μηχανή Αναζήτησης
Ειδησεογραφικών Άρθρων


ΑΜΑΛΙΑ-ΓΕΩΡΓΙΑ ΜΟΥΣΕΛΙΜΗ 5074
ΣΑΚΕΛΛΑΡΙΟΥ ΙΩΑΝΝΑ 5125

Εισαγωγή


Το σύστημα είναι μια μηχανή αναζήτησης σε μια συλλογή με ειδησεογραφικά άρθρα. Η αναζήτηση μπορεί να γίνει με τους εξής τρόπους:

- αναζήτηση με λέξεις κλειδιά
- αναζήτηση πεδίου (Author, Headline, Category, Section, Description, Second Headline, Article text, Date published)
- διανυσματική αναζήτηση


Ο χρήστης πληκτρολογεί το ερώτημα του στην γραμμή αναζήτησης της μηχανής και έπειτα μέσω των επιλογών που του παρέχονται (“Search by Keyword”, “Search by field”, “Search by Vector”), μπορεί να επιλέξει τον τρόπο αναζήτησης που επιθυμεί.

The image shows a search interface titled "Article Search". It features a search input field with the placeholder text "Search...". Below the input field, there are three radio buttons for selecting the search method: "Search By Keyword" (which is selected), "Search By Field:", and "Search By Vector". Next to the "Search By Field:" radio button is a dropdown menu currently showing "headline".


Κάτω από τις επιλογές αναζήτησης υπάρχουν επιλογές για την σειρά με την οποία θα εμφανίζονται τα αποτελέσματα της αναζήτησης. Επίσης, υπάρχει και το κουμπί για την δημιουργία ευρετηρίου, το οποίο θα χρησιμοποιηθεί μόνο μια φορά από τον χρήστη. Τέλος, υπάρχουν τα κουμπιά “Search” και “Clear”, με τα οποία ο χρήστης θα εκτελεί την αναζήτηση και θα κάνει εκκαθάριση αντίστοιχα.

The image shows a horizontal bar containing four elements: a dropdown menu labeled "Relevance", a button with a download icon labeled "Create Index", a button with a magnifying glass icon labeled "Search", and a button with an eraser icon labeled "Clear".

Τα αποτελέσματα εμφανίζονται στο κέντρο της οθόνης και υπάρχουν και βελάκια για να περιηγηθείς στην επόμενη και προηγούμενη καρτέλα αντίστοιχα.

The image shows a search results interface titled "Results:". It features a large, empty rectangular box for displaying the search results. At the bottom of the interface, there are two buttons: "Previous" with a left arrow and "Next" with a right arrow.

Στο κάτω μέρος της οθόνης υπάρχει το ιστορικό αναζήτησης του χρήστη που θα εμφανίζει τις 20 τελευταίες αναζητήσεις μαζί με τα 5 πρώτα άρθρα για κάθε μία από αυτές.



Επεξήγηση Κώδικα

Αρχικά υλοποιήσαμε την κλάση *'CsvLoader'* που είναι υπεύθυνη για την φόρτωση των δεδομένων από το αρχείο csv και τη μετατροπή τους σε δομή δεδομένων (λίστα από πίνακες συμβολοσειρών) ώστε να μπορεί να γίνει η επεξεργασία τους κατά το indexing.

Η κλάση *'Indexer'* είναι υπεύθυνη για την δημιουργία του ευρετηρίου. Η μέθοδος *'createIndex'* ξεκινά με τη φόρτωση των άρθρων από αρχείο CSV, χρησιμοποιώντας την κλάση *CsvLoader*. Κάθε γραμμή του αρχείου αντιστοιχεί σε ένα άρθρο και αποθηκεύεται ως πίνακας *String[]*. Για κάθε άρθρο, δημιουργείται ένα *Document* το οποίο περιλαμβάνει όλα τα βασικά πεδία του άρθρου: *headline*, *author*, *category*, *section*, *description*, *article_text*, *url*, *date_published*. Επίσης, στην *Indexer* δημιουργείται για κάθε άρθρο μια διανυσματική αναπαράσταση (*embedding*). Το *embedding* αυτό προκύπτει από το συνδυασμό του τίτλου, του συγγραφέα, της περιγραφής και του πλήρους κειμένου του άρθρου και της επικεφαλίδας. Το διανυσματικό πεδίο αποθηκεύεται στο *Document* μέσω του *KnnVectorField*, το οποίο επιτρέπει μελλοντική αναζήτηση βασισμένη στην ομοιότητα διανυσμάτων.

Για την υλοποίηση της διανυσματικής αναζήτησης δημιουργήσαμε και την κλάση *'EmbeddingHelper'*. Η κλάση αυτή αποτελεί μία στατική βοηθητική μονάδα υπεύθυνη για τη μετατροπή φυσικού κειμένου σε διανυσματική αναπαράσταση (*embedding*), χρησιμοποιώντας το προεπιλεγμένο μοντέλο της *HuggingFace* μέσω της βιβλιοθήκης *DJL*. Το *embedding* χρησιμοποιείται για την υποστήριξη διανυσματικής αναζήτησης με *KNN* (*K-nearest neighbors*) στο *Lucene*. Η φόρτωση του μοντέλου γίνεται μία φορά κατά την εκκίνηση, εξασφαλίζοντας αποδοτικότητα κατά την επαναλαμβανόμενη χρήση του *embedText()*.

Η κλάση *'Searcher'* είναι υπεύθυνη για την εκτέλεση αναζητήσεων στο ευρετήριο που δημιουργείται με το *Lucene*. Υποστηρίζει τρεις βασικούς τύπους αναζήτησης:

1. Αναζήτηση με λέξεις-κλειδιά (Keyword Search):

Επιτρέπει την αναζήτηση μιας λέξης ή φράσης σε πολλαπλά πεδία του άρθρου, όπως τίτλος, συγγραφέας, περιγραφή κ.ά. Η αναζήτηση βασίζεται σε συντακτική αντιστοίχιση, δηλαδή αναζητά ακριβείς όρους.

2. Αναζήτηση σε συγκεκριμένο πεδίο (Field Search):

Επιτρέπει στο χρήστη να περιορίσει την αναζήτηση σε ένα συγκεκριμένο πεδίο (π.χ. μόνο στον τίτλο ή μόνο στο συγγραφέα), ώστε να επιτευχθεί πιο στοχευμένη ανάκτηση αποτελεσμάτων.

3. Διανυσματική αναζήτηση (Vector Search):

Χρησιμοποιεί μοντέλο από τη βιβλιοθήκη DJL για να μετατρέψει το ερώτημα του χρήστη σε διάνυσμα εννοιών. Έπειτα, μέσω του μηχανισμού KnnVectorQuery, βρίσκει άρθρα που είναι σημασιολογικά σχετικά, ακόμη κι αν δεν περιέχουν τις ίδιες λέξεις.

Η κλάση φορτώνει το ευρετήριο κάθε φορά που γίνεται αναζήτηση και επιστρέφει τα αντίστοιχα έγγραφα. Η μέθοδος της διανυσματικής αναζήτησης συνδέεται άμεσα με την 'EmbeddingHelper' η οποία δημιουργεί το διάνυσμα του ερωτήματος.

Η κλάση 'HistoryManager' είναι υπεύθυνη για τη διαχείριση του ιστορικού αναζητήσεων του χρήστη. Καταγράφει μέχρι και τις 20 πιο πρόσφατες αναζητήσεις, μαζί με τα πρώτα 5 αποτελέσματα κάθε αναζήτησης (συνήθως τίτλοι άρθρων). Επιπλέον, αποθηκεύει τον τύπο της αναζήτησης (keyword, field ή διανυσματική), προσφέροντας έτσι ένα πλήρες ιστορικό της αναζήτησης που πραγματοποιήθηκε.

Η κλάση 'AppGUI' αποτελεί το γραφικό περιβάλλον χρήστη (GUI) της εφαρμογής αναζήτησης, υλοποιημένο με τη βιβλιοθήκη JavaFX. Σκοπός της είναι να παρέχει στον χρήστη ένα φιλικό και λειτουργικό περιβάλλον για να εκτελεί αναζητήσεις σε ειδησεογραφικά άρθρα.

Βασικές λειτουργίες:


- **Αναζήτηση άρθρων** με τρεις τρόπους:
 - Με βάση λέξεις-κλειδιά (σε όλα τα πεδία).
 - Με βάση συγκεκριμένο πεδίο (π.χ. τίτλος, συγγραφέας).
 - Με διανυσματική αναζήτηση (vector search).
- **Ταξινόμηση** αποτελεσμάτων ανά:
 - Σχετικότητα,
 - Αλφαβητικά (τίτλος),
 - Ημερομηνία δημοσίευσης.

- **Επισήμανση (highlighting)** των λέξεων-κλειδιών στα αποτελέσματα, με έντονη γραφή.
- **Εμφάνιση σελιδοποιημένων αποτελεσμάτων** (10 ανά σελίδα) με κουμπιά για περιήγηση σε επόμενη ή προηγούμενη σελίδα.
- **Διατήρηση ιστορικού** των τελευταίων 20 αναζητήσεων, μαζί με τους τίτλους των 5 πρώτων αποτελεσμάτων κάθε φορά.

Παραδείγματα Αναζήτησης

1. Αναζήτηση με λέξη-κλειδί

Σε αυτή τη λειτουργία, το σύστημα αναζητά την εισαγόμενη λέξη ή φράση σε όλα τα βασικά πεδία των άρθρων (τίτλος, συγγραφέας, κατηγορία, κείμενο κ.λπ.). Η αναζήτηση βασίζεται σε ακριβή συντακτική αντιστοίχιση.



Article Search

truck

☒ Search By Keyword
 ☐ Search By Field: headline
☐ Search By Vector


Relevance ▼
 Create Index
 Search
 Clear

Results:

1. Headline: **truck** carrying tomato puree crashes, turning road red - CNN
 Author: Sara Spary, CNN
 Date published: 2021-06-03 11:19:18
 Category: news
 Section: uk
 Description: A **truck** laden with tomato puree crashed in England this week, turning a highway red and prompting a number of food-related puns from people on social media.
 Article text: (CNN)A **truck** laden with tomato puree crashed in England this week, turning a highway red and prompting a number of food-related puns from people on social media. The vehicle was involved in a crash with another **truck** in Cambridgeshire, eastern England, on Tuesday, Highways England told CNN. The government highways authority said the vehicle "lost its load and damaged the carriageway," leading to a road closure on the A14. One driver sustained a "minor" injury, Highways England said. A spokesman confirmed it
 Url: <https://www.cnn.com/2021/06/03/uk/crash-tomato-puree-scli-intl-gbr/index.html>

2. Αναζήτηση σε συγκεκριμένο πεδίο

Σε αυτή την περίπτωση, ο χρήστης επιλέγει ένα πεδίο (π.χ. μόνο τίτλος ή συγγραφέας) και το σύστημα περιορίζει την αναζήτηση αποκλειστικά σε αυτό.



Article Search

Jacopo Prisco

☐ Search By Keyword
 ☒ Search By Field: author
☐ Search By Vector


Relevance ▼
 Create Index
 Search
 Clear

Results:

1. Headline: There's a shortage of truckers, but TuSimple thinks it has a solution: no driver needed - CNN
 Author: **Jacopo Prisco**, CNN
 Date published: 2021-07-15 02:46:59
 Category: news
 Section: world
 Description: The e-commerce boom has exacerbated a global truck driver shortage, but could autonomous trucks help fix the problem?
 Article text: (CNN)Right now, there's a shortage of truck drivers in the US and worldwide, exacerbated by the e-commerce boom brought on by the pandemic. One solution to the problem is autonomous trucks, and several companies are in a race to be the first to launch one. Among them is San Diego-based TuSimple. Founded in 2015, TuSimple has completed about 2 million miles of road tests with its 70 prototype trucks across the US, China and Europe. Although these are simply commercially available trucks retrofitted...
 Url: <https://www.cnn.com/2021/07/14/world/tusimple-autonomous-truck-spc-intl/index.html>

3. Διανυσματική Αναζήτηση

Όταν επιλέγουμε διανυσματική αναζήτηση, το σύστημα επιστρέφει άρθρα που είναι νοηματικά σχετικά με το ερώτημα, ακόμα και αν δεν περιέχουν τις ίδιες λέξεις.



The screenshot shows a web interface titled "Article Search". At the top, there is a search bar containing the text "How can technology help with transportation problems?". Below the search bar, there are three radio buttons for search methods: "Search By Keyword", "Search By Field:" (with a dropdown menu showing "author"), and "Search By Vector" (which is selected). To the left of the search bar is a "Relevance" dropdown menu. To the right are buttons for "Create Index", "Search", and "Clear". Below the search bar, the "Results:" section displays a list of search results. The first result is visible, showing a headline, author, date, category, section, description, article text, and URL.

Article Search

How can technology help with transportation problems?

☐ Search By Keyword ☐ Search By Field: author ☒ Search By Vector

Relevance ▼ Create Index Search Clear

Results:

1. Headline: These apps are trying to put car dealers out of business - CNN
Author: Nell Lewis, CNN Business
Date published: 2021-07-15 08:24:45
Category: business
Section: business
Description: A Finnish startup has developed a mobile app, Whim, to fix urban congestion and reduce pollution.
Article text: , stalling the company's expansion into other cities.According to Whim, public transport and micromobility are the most popular ways to travel using the app. Finnish newspaper Helsingin Sanomat recently reported that the company had spent €50 million (\$59 million) on failed expansion ventures. Hietanen says the money was spent on integrating multiple **transportation** providers, establishing market readiness in several countries, and developing the complex **technology** that underpins the app. "We've known from the
Url: <https://www.cnn.com/2021/07/15/business/whim-app-helsinki-spc-intl/index.html>

2. Headline: There's a shortage of truckers, but TuSimple thinks it has a solution: no driver needed - CNN

Πληροφορίες για τα Δεδομένα

Το σύστημα χρησιμοποιεί ως πηγή δεδομένων ένα αρχείο CSV που περιέχει ειδησεογραφικά άρθρα από το CNN. Το αρχείο αυτό έχει ληφθεί από τον παρακάτω σύνδεσμο:

Link προς dataset:

<https://www.kaggle.com/datasets/hadasu92/cnn-articles-after-basic-cleaning/data>

Περιγραφή δομής

Το αρχείο είναι σε μορφή .csv και κάθε γραμμή του περιέχει ένα άρθρο. Τα πεδία του CSV περιλαμβάνουν:

- index – μοναδικό ID του άρθρου
- author – όνομα του συγγραφέα
- date_published – ημερομηνία δημοσίευσης
- category – κατηγορία άρθρου
- section – ενότητα (π.χ. opinion, politics)
- url – σύνδεσμος στο άρθρο
- headline – κύριος τίτλος
- description – σύντομη περιγραφή
- keywords – λέξεις-κλειδιά

- second_headline – δευτερεύων τίτλος
- article_text – πλήρες κείμενο άρθρου

Κατά τη δημιουργία του ευρετηρίου, κάθε άρθρο φορτώνεται και αποθηκεύεται ως Document στο Lucene. Ορισμένα πεδία χρησιμοποιούνται και για τον υπολογισμό διανυσμάτων (vector embeddings).