




Ανάκτηση Πληροφορίας

Αρχιτεκτονική RAG

ΑΜΑΛΙΑ-ΓΕΩΡΓΙΑ ΜΟΥΣΕΛΙΜΗ 5074
ΣΑΚΕΛΛΑΡΙΟΥ ΙΩΑΝΝΑ 5125

Εισαγωγή

Σκοπός της παρούσας εργασίας ήταν η υλοποίηση ενός συστήματος ερώτησης-απάντησης (Question Answering - QA), βασισμένου στην αρχιτεκτονική RAG (Retrieval-Augmented Generation). Το σύστημα αξιοποιεί δεδομένα ειδησεογραφικών άρθρων του CNN και επιτρέπει στον χρήστη να υποβάλλει ερωτήματα, στα οποία η απάντηση προκύπτει μέσω ανάκτησης σχετικών πληροφοριών και γλωσσικής επεξεργασίας από ένα μεγάλο γλωσσικό μοντέλο (LLM).

Περιγραφή της Αρχιτεκτονικής RAG

Η RAG αποτελεί συνδυαστική προσέγγιση ανάμεσα στην **ανάκτηση πληροφορίας (retrieval)** και στη **γλωσσική παραγωγή (generation)**. Περιλαμβάνει δύο στάδια:

1. Ανάκτηση (Retrieval):

Το ερώτημα του χρήστη μετατρέπεται σε διάνυσμα (embedding) και συγκρίνεται με ενσωματωμένα τμήματα (chunks) κειμένου από τα άρθρα, τα οποία έχουν αποθηκευτεί σε διανυσματική βάση (FAISS). Επιστρέφονται τα Κ πιο σχετικά chunks.

2. Παραγωγή (Generation):

Τα ανακτημένα chunks και το ερώτημα χρησιμοποιούνται ως είσοδος σε ένα LLM (llama3.2), το οποίο παράγει τελική απάντηση βάσει των συμφραζομένων.

Αυτό επιτρέπει την αξιοποίηση εξωτερικής πληροφορίας, βελτιώνοντας την ακρίβεια των απαντήσεων και περιορίζοντας την «εφευρετικότητα» του μοντέλου.

Η RAG αρχιτεκτονική αποτελείται από τα εξής βασικά χαρακτηριστικά:

- **Text Splitter:** Χωρίζει τα έγγραφα σε μικρότερα chunks (RecursiveCharacterTextSplitter).
- **Embeddings:** Μετατροπή chunks και ερωτήσεων σε διανύσματα (HuggingFace `all-MiniLM-L6-v2`).
- **Vector Store:** Αποθήκευση και αναζήτηση εγγράφων με βάση την ομοιότητα (FAISS).
- **Retriever + LLM:** Συνδυασμός ανακτώμενων εγγράφων με το ερώτημα στο LLM για παραγωγή απάντησης.

Υλοποίηση Συστήματος

Η υλοποίηση του συστήματος βασίστηκε στο πλαίσιο LangChain σε συνδυασμό με τοπικά Large Language Models (LLMs) μέσω του Ollama. Η εφαρμογή υλοποιήθηκε σε δύο κύρια στάδια: προεπεξεργασία δεδομένων και διάλογος RAG.

1. Προεπεξεργασία και Δημιουργία FAISS Βάσης

Τα βήματα που υλοποιήθηκαν ήταν:

- *Φόρτωση Δεδομένων:* Τα άρθρα φορτώθηκαν από αρχείο CSV (`CNN\_Articles\_clean.csv`), με το κείμενο να εξάγεται από τη στήλη `Article text`.
- *Κατακερματισμός Κειμένου (Chunking):* Χρησιμοποιήθηκε το RecursiveCharacterTextSplitter με μέγεθος chunk 500 χαρακτήρες και επικάλυψη 50 χαρακτήρες για να διατηρηθεί η συνοχή του περιεχομένου.
- *Μετατροπή σε Διανύσματα (Embeddings):* Κάθε chunk μετατράπηκε σε διάνυσμα μέσω του μοντέλου all-MiniLM-L6-v2 της βιβλιοθήκης sentence-transformers.
- *Αποθήκευση σε FAISS:* Όλα τα embeddings αποθηκεύτηκαν σε διανυσματική βάση FAISS, ώστε να μπορούν να ανακτηθούν τα σχετικά chunks κατά το ερώτημα του χρήστη.

2. Ερώτηση-Απάντηση με RAG

Το τελικό σύστημα διαλόγου βασίστηκε στο σχήμα Retrieval-Augmented Generation:

- *Ενσωμάτωση Ερωτήματος:* Η ερώτηση του χρήστη μετατρέπεται σε embedding και συγκρίνεται με τα αποθηκευμένα chunks στη FAISS βάση.
- *Ανάκτηση Σχετικών Chunks:* Τα top-k (k=4) πιο σχετικά chunks ανακτώνται.
- Το prompt format δημιουργείται εσωτερικά από το RetrievalQA chain και δεν χρειάζεται χειροκίνητη διαμόρφωση.

Απάντηση μέσω LLM: Το prompt προωθείται στο μοντέλο llama3.2 μέσω του Ollama και παράγει την τελική απάντηση.

CLI Διάλογος: Ο χρήστης μπορεί να κάνει ερωτήσεις σε πραγματικό χρόνο μέσω γραμμής εντολών, και το σύστημα απαντάει χρησιμοποιώντας RAG.

Αξιολόγηση & Πειραματικά Αποτελέσματα

Για την αξιολόγηση του RAG συστήματος δημιουργήθηκε ένα νέο script evaluate.py στο οποίο τυπώνονται τα αποτελέσματα από 5 ερωτήσεις με και χωρίς την χρήση context. Ο σκοπός ήταν να αναδειχθεί η συνεισφορά του retrieval στα αποτελέσματα του LLM.

Μεθοδολογία

Χρησιμοποιήθηκε ένα σύνολο από 5 ερωτήσεις σχετικές με τα άρθρα του dataset. Για κάθε ερώτηση συλλέχθηκαν:

- Η απάντηση από το RAG σύστημα (με χρήση FAISS και relevant chunks).
- Τα chunks που χρησιμοποιήθηκαν για την απάντηση με context.
- Η απάντηση απευθείας από το LLM χωρίς παροχή context.

Τα ερωτήματα που χρησιμοποιήθηκαν ήταν:

1. What is TuSimple's plan for autonomous trucks?
2. What are the benefits of the Ironhand glove?
3. What is the impact of EU sanctions on Russian energy?
4. Who was the protester on Russian state television and what did she do?
5. How have oil prices changed due to the war in Ukraine?

Οι απαντήσεις και τα αντίστοιχα chunks καταγράφονται στο αρχείο `evaluation_results.txt`.